

Báo cáo Kỹ thuật R&D: Kiến trúc và Giải pháp Bóc tách Dữ liệu Hồ sơ Ứng viên (CV Parsing) cho Hệ thống miCareer-x-Fang

1. Bối cảnh và mục tiêu

Nhu cầu tự động hóa quy trình tuyển dụng và quản trị nguồn nhân lực đang thúc đẩy sự chuyển dịch mạnh mẽ từ các hệ thống Quản lý Ứng viên (Applicant Tracking System - ATS) truyền thống sang các nền tảng được hỗ trợ bởi Trí tuệ Nhân tạo (AI). Trong bối cảnh phát triển của dự án miCareer-x-Fang — một hệ thống sản tuyển dụng tích hợp mini-ATS — việc xây dựng một lớp AI (AI Layer) độc lập dựa trên kiến trúc Retrieval-Augmented Generation (RAG) đóng vai trò then chốt [1].

Điểm khởi đầu và cũng là nút thắt cổ chai của toàn bộ luồng xử lý dữ liệu RAG chính là khả năng phân tích cú pháp (parsing) hồ sơ ứng viên (CV) một cách chính xác, nhanh chóng và có cấu trúc [1].

Báo cáo kỹ thuật này trình bày một đánh giá toàn diện về các giải pháp bóc tách CV trên thị trường, với trọng tâm đặt vào ba nền tảng hàng đầu: Affinda, Google Gemini 3.1 (Pro/Flash), và Sovren (Textkernel). Mục tiêu cốt lõi là đề xuất một kiến trúc bóc tách dữ liệu bền bỉ, tối ưu chi phí, hỗ trợ xuất sắc đa ngôn ngữ (đặc biệt là tiếng Việt và tiếng Anh), và đảm bảo kết xuất dữ liệu dưới định dạng JSON có cấu trúc tĩnh [1].

Dữ liệu này sau đó sẽ được lưu trữ vào cơ sở dữ liệu PostgreSQL (bảng CVParsed) và phục vụ cho quy trình chunking cũng như embedding trong môi trường Python FastAPI [1].

2. Kiến trúc hệ thống và yêu cầu kỹ thuật cốt lõi

Hệ thống miCareer-x-Fang được thiết kế theo nguyên lý đảo pha (phase-inverted architecture), trong đó logic nghiệp vụ AI được tách biệt hoàn toàn khỏi Web Core (viết bằng Java Servlet/JSP) [1]. Lõi AI (AI Core) được triển khai trên nền tảng Python 3.10+ sử dụng framework FastAPI, vận hành bất đồng bộ (async) với máy chủ Uvicorn, giao tiếp HTTP qua thư viện httpx, và quản lý cấu hình thông qua pydantic-settings kết hợp python-dotenv [1].

Mỗi khi một ứng viên nộp hồ sơ, Web Core sẽ khởi tạo một bản ghi JobApplication và gửi yêu cầu chứa jobId cùng đường dẫn tệp cvSnapUrl (được lưu trữ trên Cloudinary hoặc Firebase) sang AI Core [1]. Từ đây, quy trình nhập liệu (ingestion workflow) bắt đầu.

Luồng xử lý dữ liệu chuẩn trong hệ thống như sau: JobApplication → CVParsed → AIDocumentChunk → RAG Retrieval.

Theo thiết kế cơ sở dữ liệu chuẩn hóa 3NF của dự án, thông tin trích xuất sẽ được ghi nhận vào bảng CVParsed với các trường chính bao gồm cvParsedId (khóa chính), jobId (khóa ngoại, quan hệ 1:1), rawText, định danh công cụ bóc tách (parserVer), và nhãn thời gian parseAt [2]. Toàn bộ khối văn bản thô sau đó được chia nhỏ thành các đoạn (chunk), được mô hình hóa thành vector 1536 chiều, và lưu vào bảng AIDocumentChunk sử dụng extension pgvector 0.8.2 trên PostgreSQL 18.3 [1].

Để hệ thống hoạt động trơn tru, bộ phận R&D đặt ra các tiêu chí khắt khe đối với giải pháp bóc tách CV:

- Chi phí thấp hoặc miễn phí trong giai đoạn DEV/DEMO nhằm giảm rủi ro tài chính [1].
- Hỗ trợ tiếng Việt và tiếng Anh với độ chính xác cao, phù hợp bối cảnh thị trường lao động IT tại Việt Nam [1].
- JSON output phải hợp lệ tuyệt đối để vượt qua vòng validation của Pydantic trong FastAPI [1].
- Giải pháp cần bền bỉ trước các định dạng khó như PDF scan chất lượng thấp, hình ảnh nhiễu, hoặc CV có bố cục phi truyền thống [1].

3. Đánh giá năng lực nhà cung cấp

3.1. Affinda: Nền tảng học máy chuyên biệt cho tuyển dụng

Affinda là một nền tảng AI chuyên xử lý tài liệu, nổi bật với sản phẩm Resume Parser được tinh chỉnh sâu cho nghiệp vụ tuyển dụng. Thay vì sử dụng mô hình LLM có nguy cơ sinh ra hallucination, Affinda triển khai mô hình học máy tĩnh được huấn luyện để nhận diện các mẫu cấu trúc CV [5].

Điểm mạnh của Affinda nằm ở độ sâu của cấu trúc JSON trả về. Giải pháp này tự động phân loại dữ liệu thành hàng trăm trường vì mô, từ thông tin cá nhân, học vấn, kinh nghiệm làm việc, cho đến việc phân nhóm kỹ năng và chuẩn hóa theo mã phân loại nghề nghiệp. Affinda hỗ trợ hơn 50 ngôn ngữ, bao gồm khả năng nhận diện tiếng Việt ở mức khá tốt, đồng thời có OCR tích hợp để xử lý PDF scan và ảnh tài liệu [1] [8].

Hạn chế lớn nhất là chi phí và chính sách dùng thử. Nền tảng này không cung cấp free tier vĩnh viễn cho nhà phát triển; thông thường chỉ có 14 ngày dùng thử hoặc giới hạn nhỏ (ví dụ 200 lượt test) trước khi chuyển sang mô hình tính phí theo lượt hoặc theo năm [8] [10]. Ngoài ra, rate limit ở một số hàng đợi được thiết lập ở mức 30 tài liệu/phút, vượt mức có thể nhận lỗi HTTP 429 [13].

3.2. Google Gemini 3.1 Pro/Flash: Sức mạnh đa phương thức và đầu ra cấu trúc

Dòng mô hình Gemini 3.1 (Pro/Flash) đại diện cho thế hệ AI sinh tạo đa phương thức hiện đại của Google. Không giống pipeline OCR truyền thống phải tách riêng bước OCR rồi mới đưa vào NLP, Gemini có khả năng đọc và hiểu trực tiếp tệp PDF dưới dạng hình ảnh và ngữ cảnh tài liệu [14].

Năng lực native OCR của Gemini là ưu điểm nổi bật. Do xử lý kết hợp vision và language, mô hình có thể hiểu quan hệ không gian giữa các khối văn bản và giữ được ngữ cảnh bố cục của CV — điều mà nhiều OCR truyền thống thường làm xáo trộn. Với CV tiếng Việt hoặc song ngữ Việt – Anh, Gemini được kỳ vọng có lợi thế nhờ khả năng hiểu ngữ cảnh và thuật ngữ chuyên ngành IT [1] [17].

Về tích hợp, Gemini hỗ trợ Structured Outputs: có thể khai báo `response_mime_type = "application/json"` và truyền trực tiếp JSON Schema sinh từ `Pydantic model_json_schema()`. Cơ chế này giúp khóa định dạng đầu ra ở mức token, từ đó bảo đảm JSON phù hợp schema và có thể kiểm tra bằng `model_validate_json()` một cách an toàn [4].

Lợi thế cạnh tranh mạnh nhất của Gemini là chi phí. Google AI Studio cung cấp hạn mức miễn phí rất phù hợp cho giai đoạn DEV/DEMO. Khi chạy trong môi trường PROD trên Vertex AI, chi phí theo token của Flash/Pro thấp hơn đáng kể so với các dịch vụ SaaS chuyên biệt tính phí theo CV hoặc theo trang [1] [24].

3.3. Sovren (Textkernel): Tiêu chuẩn công nghiệp, thiên về enterprise

Sovren là một trong những động cơ bóc tách CV và JD lâu đời trên thị trường, được nhiều doanh nghiệp nhân sự quy mô lớn sử dụng. Nền tảng này hỗ trợ nhiều ngôn ngữ, có khả năng phân tích hồ sơ sâu và tích hợp thêm semantic matching cho kịch bản xếp hạng ứng viên [27] [30].

Tuy nhiên, Sovren được định vị ở phân khúc enterprise, chi phí cao, quá trình cấu hình tương đối nặng hơn, và bộ trường dữ liệu trả về có thể quá lớn so với nhu cầu vừa đủ của kiến trúc RAG trong dự án miCareer-x-Fang [5] [32].

4. So sánh tổng quan năng lực nhà cung cấp

Tiêu chí	Affinda	Google Gemini 3.1 (Flash/Pro)	Sovren (Textkernel)
Công nghệ cốt lõi	Học máy tính (ML) + OCR chuyên biệt	Mô hình ngôn ngữ lớn đa phương thức (VLM)	NLP theo hướng enterprise, kết hợp quy tắc và ML
Mức độ hỗ trợ tiếng Việt	Tốt	Xuất sắc	Khả
Xử lý PDF scan / hình ảnh	Tốt nhờ OCR tích hợp	Xuất sắc nhờ đọc PDF/ảnh trực tiếp và hiểu bố cục	Tốt
Mức độ linh hoạt schema	Thấp – phụ thuộc schema có sẵn	Rất cao – định nghĩa qua Pydantic/JSON Schema	Trung bình – thiên về schema cố định chuẩn HR
JSON validity	100% (REST API trả dữ liệu cấu trúc)	100% nếu dùng Structured Outputs	100% (REST API trả dữ liệu cấu trúc)
Chi phí DEV/DEMO	Dùng thử giới hạn thời gian/lượt test	Miễn phí trong Google AI Studio (giới hạn tốc độ)	Không có free tier mở rộng
Chi phí PROD	Khoảng 0.13–0.20 USD/CV tùy gói	Rất thấp theo token	Khởi điểm từ gói doanh nghiệp / accelerator
Độ trễ trung bình	1–3 giây/CV	5–15 giây/CV	Thường rất nhanh

5. Thiết kế tập test và kịch bản đánh giá

Để định lượng hiệu năng thực tế của các giải pháp, một testset quy mô nhỏ nhưng có độ phủ cao cần được xây dựng, gồm 15 CV bao quát cả use case phổ biến lẫn edge case trong hệ sinh thái tuyển dụng IT.

- Phân bố ngôn ngữ: 5 CV tiếng Anh, 5 CV tiếng Việt, 5 CV song ngữ Việt – Anh.
- Định dạng tệp: 5 PDF text-based, 5 PDF scan chất lượng thấp, 5 ảnh JPEG/PNG chụp từ điện thoại.

- Độ phức tạp bố cục: CV 1 trang nhiều cột, CV 2 trang chuẩn dòng thời gian, CV 3–4 trang cho senior/lead, và các edge case có nhiều đồ họa hoặc trật tự thời gian bất thường.

Bốn nhóm tiêu chí đánh giá cốt lõi gồm:

- JSON Validity Rate: đo tỷ lệ tệp vượt qua validation của Pydantic mà không phát sinh exception.
- Field Coverage & Accuracy: đo độ chính xác của các trường quan trọng như fullName, emails, education.school, experiences.company, và chất lượng trường rawText.
- Robustness: kiểm tra khả năng xử lý bản scan xấu, ảnh nhiễu, hoặc bố cục dị biệt mà không bị crash/hang.
- Cost Projections: dự phóng chi phí ở DEV/DEMO (ví dụ 200 CV/tháng) và PROD (ví dụ 10.000 CV/tháng).

6. Đề xuất chuẩn hóa dữ liệu và kiến trúc chịu lỗi

6.1. Chuẩn hóa schema JSON và nguyên tắc prompt

Kiến trúc AI Core áp dụng cách tiếp cận schema-first thông qua Pydantic. Các thực thể dữ liệu được định nghĩa chặt chẽ trong `app/models/cv_models.py` để FastAPI vừa tự động sinh tài liệu OpenAPI, vừa ép buộc LLM trả về cấu trúc tương ứng [1].

Về chuẩn hóa ngày tháng, mọi mốc thời gian trong CV nên được chuyển về định dạng YYYY-MM theo ISO 8601 subset; riêng trạng thái đang làm việc/học tập được chuẩn hóa thành "present". Cách làm này giúp loại bỏ mơ hồ giữa các phong cách ghi ngày khác nhau và hỗ trợ truy vấn kinh nghiệm một cách chính xác [36] [39] [41].

Các quy tắc prompt nên bao gồm: không bịa đặt dữ liệu, trường string thiếu thông tin trả về "", trường array trả về [], gộp kỹ năng thành mảng chuỗi đơn giản, và ghi toàn bộ nội dung văn bản trích xuất vào rawText theo đúng trật tự luồng đọc của CV [1].

6.2. Thiết kế kiến trúc chịu lỗi nhiều tầng (Multi-tier Fallback Architecture)

Để tránh vendor lock-in và giảm single point of failure, kiến trúc parser nên áp dụng cơ chế fallback nhiều tầng trong `app/services/cv_parser.py` như sau:

- Tầng 1 (Primary Model): Google Gemini 3.1 Flash – công cụ xử lý mặc định nhờ chi phí thấp, hỗ trợ đa phương thức, và Structured Outputs.
- Tầng 2 (Secondary Fallback): Google Gemini 3.1 Pro – dùng khi tài liệu quá phức tạp, scan xấu, hoặc cần suy luận bố cục nâng cao.
- Tầng 3 (Tertiary Fallback / Dead-Letter Queue): Affinda API – kích hoạt khi cả hai mô hình Gemini thất bại do rate limit, lỗi parsing, hoặc bị safety filter chặn nhầm.

Nếu dữ liệu đi qua cả ba tầng mà vẫn thất bại, trạng thái trong `AIIndexJob` nên được cập nhật thành FAILED; thông báo lỗi ghi vào `errorMsg` và `retryCount` tăng lên để phục vụ kiểm tra thủ công [1].

7. Quyết định lộ trình triển khai

Giai đoạn DEV/DEMO: sử dụng duy nhất Google Gemini 3.1 Flash thông qua Google AI Studio API. Lý do là chi phí bằng 0 ở mức thử nghiệm, đủ để thiết lập và kiểm thử toàn bộ pipeline từ JobApplication → CVParsed → AIDocumentChunk → RAG Retrieval; đồng thời thuận tiện khi dùng chung một API key và Structured Outputs để kiểm thử Pydantic schema [1] [4].

Giai đoạn PROD: triển khai kiến trúc chịu lỗi nhiều tầng với Gemini 3.1 Flash làm lõi, fallback sang Gemini 3.1 Pro và Affinda. Mục tiêu là tối ưu chi phí biên theo token nhưng vẫn đảm bảo độ ổn định cao cho toàn bộ luồng ingestion của hệ thống [1] [25].

8. Đầu ra JSON mẫu minh họa (đã sửa cú pháp)

Phần này đã được sửa trực tiếp để bảo đảm mọi ví dụ JSON đều hợp lệ, nhất quán với chính yêu cầu JSON validity và validation của Pydantic/FastAPI.

Mẫu 1: CV tiếng Việt tiêu chuẩn (Backend Developer)

```
{
  "parserVer": "gemini-3.1-flash",
  "candidate": {
    "fullName": "Nguyễn Văn A",
    "emails": ["nva.backend@micareer.vn"],
    "phones": ["0987654321"],
    "location": "Quận Cầu Giấy, Hà Nội"
  },
  "education": [
    {
      "school": "Đại học Bách Khoa Hà Nội",
      "degree": "Cử nhân CNTT",
      "startDate": "2018-09",
      "endDate": "2022-06"
    }
  ],
  "experiences": [
    {
      "company": "FPT Software",
      "title": "Backend Java Developer",
      "startDate": "2022-07",
      "endDate": "present",
      "description": "Phát triển REST API bằng Spring Boot và PostgreSQL; tối ưu truy vấn, tích hợp Redis cache và triển khai microservices trên Docker/AWS."
    },
    {
      "company": "VNG Corporation",
      "title": "Software Engineering Intern",
      "startDate": "2021-12",
      "endDate": "2022-05",

```

```

        "description": "Hỗ trợ bảo trì hệ thống backend nội bộ và viết unit test đạt độ phủ cao."
    },
    ],
    "skills": ["Java", "Spring Boot", "PostgreSQL", "Redis", "Docker", "AWS", "Git", "REST API"],
    "certificates": ["AWS Certified Developer - Associate"],
    "languages": ["Tiếng Anh (TOEIC 750)", "Tiếng Việt (Bản xứ)"],
    "summary": "Backend Developer với gần 4 năm kinh nghiệm chuyên sâu trong hệ sinh thái Java.",
    "rawText": "Nguyễn Văn A\nBackend Java Developer\n0987654321 | nva.backend@micareer.vn | Cầu Giấy, Hà Nội\n..."
}

```

Mẫu 2: CV sinh viên mới ra trường thiếu trường dữ liệu (Scanned PDF Edge Case)

```

{
  "parserVer": "gemini-3.1-pro-fallback",
  "candidate": {
    "fullName": "Lê Thị Q",
    "emails": ["ltq.data@example.com"],
    "phones": [],
    "location": "TP. Hồ Chí Minh"
  },
  "education": [
    {
      "school": "Đại học Khoa học Tự nhiên TP.HCM",
      "degree": "Kỹ sư Khoa học Dữ liệu",
      "startDate": "2019-08",
      "endDate": "2024-02"
    }
  ],
  "experiences": [
    {
      "company": "VNG",
      "title": "Thực tập sinh Data",
      "startDate": "2023-10",
      "endDate": "2024-01",
      "description": "Xây dựng ETL pipeline đơn giản bằng Python, hỗ trợ chuyển đổi dữ liệu và làm sạch bộ dữ liệu 100K bản ghi."
    }
  ],
  "skills": ["Python", "MySQL", "Git", "Linux", "ETL Pipeline"],
  "certificates": [],
  "languages": [],
  "summary": "",
  "rawText": "LÊ THỊ Q\nỨNG TUYỂN: Data Engineer Fresher\nEmail: ltq.data@example.com\nKhu vực: TP. Hồ Chí Minh\n..."
}

```

Mẫu 3: CV tiếng Anh cao cấp đa quốc gia (Fullstack Senior)

```
{
  "parserVer": "gemini-3.1-flash",
  "candidate": {
    "fullName": "Michael Nguyen",
    "emails": ["michael.ng@globaltech.io"],
    "phones": ["+84 912 345 678"],
    "location": "Ho Chi Minh City, Vietnam"
  },
  "education": [
    {
      "school": "University of Information Technology",
      "degree": "B.S. in Computer Science",
      "startDate": "2015-09",
      "endDate": "2019-06"
    }
  ],
  "experiences": [
    {
      "company": "Tech Innovators Inc.",
      "title": "Senior Fullstack Developer",
      "startDate": "2021-01",
      "endDate": "present",
      "description": "Architected and maintained scalable web applications using ReactJS and NodeJS; led migration from monolith to microservices and mentored 4 junior developers."
    },
    {
      "company": "Startup Hub",
      "title": "Frontend Developer",
      "startDate": "2019-06",
      "endDate": "2020-12",
      "description": "Developed responsive UIs with VueJS and Tailwind CSS; integrated REST APIs and optimized performance."
    }
  ],
  "skills": ["JavaScript", "TypeScript", "ReactJS", "NodeJS", "VueJS", "MongoDB", "PostgreSQL", "Microservices", "System Design"],
  "certificates": ["Certified Kubernetes Administrator", "Scrum Master Certified"],
  "languages": ["English (IELTS 8.0)", "Vietnamese (Native)"],
  "summary": "Results-driven Senior Fullstack Developer with over 6 years of experience building high-performance web applications.",
  "rawText": "Michael Nguyen\nHo Chi Minh City, Vietnam | +84 912 345 678 | michael.ng@globaltech.io\n..."
}
```

9. Kết luận

Kiến trúc và giải pháp được đề xuất cung cấp một nền tảng vững chắc, tối ưu về chi phí và công nghệ, giúp hệ thống miCareer-x-Fang có thể tự động bóc tách và phân tích hàng nghìn hồ sơ ứng viên với chất lượng dữ liệu cao, sẵn sàng phục vụ cho các tác vụ RAG ở các giai đoạn tiếp theo.

10. Tài liệu tham khảo (đã chuẩn hóa định dạng)

- [1] yêu_cầu_ttcs_tuan1.docx; Đăng kí nhóm TTCS + đề tài; Sprint1&2: Data Core (tài liệu nội bộ dự án).
- [2] Structured outputs | Gemini API | Google AI for Developers. Truy cập ngày 29/03/2026.
- [3] Getting Started - Affinda Documentation. Truy cập ngày 29/03/2026.
- [4] Platform pricing - Affinda. Truy cập ngày 29/03/2026.
- [5] Volume and File Limits - Affinda Documentation. Truy cập ngày 29/03/2026.
- [6] Document understanding | Gemini API | Google AI for Developers. Truy cập ngày 29/03/2026.
- [7] Gemini Developer API pricing. Truy cập ngày 29/03/2026.
- [8] Sovren Resume Parser | Sovren and Textkernel Integration. Truy cập ngày 29/03/2026.
- [9] AI-Powered Job & Resume Parsing Software - Textkernel. Truy cập ngày 29/03/2026.
- [10] Các nguồn benchmark và bài viết phụ trợ về OCR, resume parsing, date formatting, prompting guide và layout-aware parsing được sử dụng như tài liệu tham khảo bổ sung trong bản gốc.